

Lista de algébrin numérica

CARLOS EDUARDO DE LIMA PEREIRA

May 2026

Q1.

Se P é projetor ortogonal sabemos que P é hermitiano e $P^2 = P$. Então:

$$(I - 2P)^* = (I - 2P)$$

que implica

$$(I - 2P)^*(I - 2P) = (I - 2P)(I - 2P)^* = I - 2P - 2P - 4P^2 = I$$

Ou seja é ortogonal.

Geometricamente, um vetor v pertencente ao subespaço que P projeta é invertido, pois $(I - 2P)v = -v$. Podemos então pensar que essa matriz reflete o subespaço de P em relação ao subespaço ortogonal.

Algorithm 8.1. Modified Gram-Schmidt

```

for  $i = 1$  to  $n$ 
     $v_i = a_i$ 
for  $i = 1$  to  $n$ 
     $r_{ii} = \|v_i\|$ 
     $q_i = v_i / r_{ii}$ 
    for  $j = i + 1$  to  $n$ 
         $r_{ij} = q_i^* v_j$ 
         $v_j = v_j - r_{ij} q_i$ 

```

Figure 1: Exemplo de reflexão de um vetor $u = \alpha \hat{x} + \beta \hat{y}$ onde $P = \hat{x} \hat{x}^T$

Q2.

$A \in C^{m \times n}$

Seja $A^* A \in C^{n \times n}$ não singular, se A não tiver posto cheio, então existe $v \neq 0 \in C^n$ tal que $Av = 0$. E por que consequência $A^* Av = 0$. Logo para o produto ser singular é necessário A posto cheio. Como $A^* A$ é não singular, ela tem que ter posto n , daí é necessário a condição $m \geq n$ pois o posto de A é menor igual que o mínimo entre m e n .

Seja A de posto cheio, então $Ax = 0$ é 0 somente no caso trivial $x = 0$. $Ax = 0$ então $x^* A^* Ax = 0$. Daí temos

$$(Ax)^*(Ax) = |Ax|^2 = 0$$

pela propriedade da norma $x = 0$.

Portanto $x^* A^* Ax = 0$ se e somente se $x = 0$

Q3.

P projetor e

$$\|P\|_2 = \sup_{x \neq 0} \frac{\|Px\|_2}{\|x\|_2}$$

suponha u autovetor de P , então

$$Pu = \lambda u$$

$$PPu = \lambda Pu$$

Usando o fato que $PP = P$

$$Pu = \lambda^2 u = \lambda u$$

Podemos projetar P quantas vezes quisermos, então para que isso seja consistente precisamos que $\lambda = 1$ ou que $\lambda = 0$. Deve existir, pelo fato de P ser não nulo, autovetor u associado ao autovalor 1. Sabemos que

$$\frac{\|Pu\|_2}{\|u\|_2} \leq \sup_{x \neq 0} \frac{\|Px\|_2}{\|x\|_2} = \|P\|_2$$

$$\frac{\|Pu\|_2}{\|u\|_2} = \frac{\|1 \cdot u\|_2}{\|u\|_2} = 1 \leq \|P\|_2$$

Agora suponha que P é ortonormal, então P é hermitiano. Então existe base ortonormal de autovetores de P associados aos autovalores 1 ou 0. Seja v_i uma base de autovetores de P , escreva então o vetor arbitrário:

$$x = \sum c_i v_i$$

$$Px = \sum \lambda_i c_i v_i$$

Onde λ_i é 0 ou 1. Pelo fato da base ser ortonormal, temos que.

$$\|Px\|_2 = \sum |c_i|^2 |\lambda_i|^2 \leq \max_i (|\lambda_i|^2) \sum |c_i|^2$$

Então, para qualquer x arbitrário:

$$\frac{\|Px\|_2}{\|x\|_2} \leq \frac{\max_i (|\lambda_i|^2) \sum |c_i|^2}{\sum |c_i|^2} = \max_i (|\lambda_i|^2)$$

Logo a norma é cotada superiormente pelo módulo quadrado do maior autovalor, como é um projetor, esse maior autovalor é 1. E como concluído antes, a norma também é cotada inferiormente por 1. Concluindo que a norma é 1.

Agora suponha que $\|P\|_2 = 1$.

Um vetor pode ser decomposto na forma

$$x = u + y$$

onde y pertence ao núcleo de P e u a imagem de P .

Sabemos que:

$$\|x\|_2^2 = \|u\|_2^2 + u^* y + y^* u + \|y\|_2^2 = \|u\|_2^2 + 2\operatorname{Re}(u^* y) + \|y\|_2^2$$

Se o núcleo e a imagem forem espaços ortogonais é apenas o caso anterior. Vamos observar então o caso em que os subespaços não são ortogonais. Então é possível escolher u e y em que o produto interno não é zero. Chame $y =$

$-t(\hat{y}^*u)\hat{y}$. A ideia aqui é mostrar que existe vetor cujo módulo é menor que o módulo de sua projeção.

$$2\operatorname{Re}(u^*y) + \|y\|_2^2 = -2t|u^*\hat{y}| + t^2|u^*\hat{y}^2| \cdot \|\hat{y}\|_2^2$$

Sabemos que para t suficientemente próximo de zero o polinômio assume valores negativos. Então podemos achar t , tal que:

$$\|x\|_2^2 < \|u\|_2^2$$

Daí a conclusão é óbvia.

$$\frac{\|Px\|_2}{\|x\|_2} = \frac{\|u\|_2}{\|x\|_2} > 1$$

Logo se é possível encontrar $u^*y \neq 0$ então entraos em contradição com a hipótese $\|P\|_2 = 1$. Daí necessitamos, portanto, que os subespaços sejam ortonormais.

Q4.

Vamos definir as duas matrizes 3×2 .

$$A_i = \begin{pmatrix} x^{(i)} & y^{(i)} \end{pmatrix} = Q_i R_i$$

para $i = 1, 2$.

Obtemos então a matriz 3×3 ortogonal Q_1 e Q_2 da forma:

$$Q_i = \begin{pmatrix} q_1^{(i)} & q_2^{(i)} & q_3^{(i)} \end{pmatrix}$$

Por construção, sabemos que o vetor $q_3^{(i)}$ é ortogonal aos outros dois que compõem a matriz, e que portanto é ortogonal ao plano P^i . Agora vamos então escrever a matriz 3×2 e sua decomposição QR.

$$\begin{pmatrix} q_3^{(1)} & q_3^{(2)} \end{pmatrix} = Q_3 R_3$$

Tal qual anteriormente, na matriz ortogonal 3×3 Q_3 o vetor $q_3^{(3)}$ que completa a base é ortogonal aos outros 2 e por consequência, é ortogonal a $q_3^{(1)}$ e $q_3^{(2)}$. E portanto $q_3^{(3)}$ está tanto no plano em que $q_3^{(1)}$ é ortogonal, quanto no plano em que $q_3^{(2)}$ é ortogonal, respectivamente, P_1 e P_2 . Portanto qualquer vetor em $P = P_1 \cap P_2$ é múltiplo de $q_3^{(3)}$.

Q5.

Algorithm 8.1. Modified Gram–Schmidt

```
for  $i = 1$  to  $n$ 
     $v_i = a_i$ 
    for  $i = 1$  to  $n$ 
         $r_{ii} = \|v_i\|$ 
         $q_i = v_i / r_{ii}$ 
        for  $j = i + 1$  to  $n$ 
             $r_{ij} = q_i^* v_j$ 
             $v_j = v_j - r_{ij} q_i$ 
```

Figure 2: Enter Caption

Para cada passo i :

$$r_{ii} = \|v_i\|$$

como v_i é um vetor de tamanho m , então são feitos $m - 1$ somas e m multiplicação.

$$q_i = v_i / r_{ii}$$

São feitas m divisões.

Para cada passo j :

$$r_{ij} = q_i^* v_j$$

são feitas m multiplicações e $m - 1$ somas.

$$v_j = v_j - r_{ij} q_i$$

aqui são feitos m produtos e m subtrações

Enstão cada operação em j é multiplicado por $n - i$.

Vamos agora somar tudo.

SOMA:

$$(m - 1) \cdot n + (m - 1) \sum_{i=1}^n (n - i)$$

MULTIPLICAÇÃO:

$$m \cdot n + 2m \sum_{i=1}^n (n-i)$$

SUBTRAÇÕES:

$$m \sum_{i=1}^n (n-i)$$

DIVISÕES:

$$m \cdot n$$

Q6.

$$F = I - 2xx^*$$

O refletor tem a mesma estrutura do operador em da questão 1 daquela lista. Como já dito naquela questão, aquilo reflete os vetores múltiplos de x com relação ao subespaço perpendicular a x . Só com isso a gente já é possível concluir que os possíveis autovetores sejam 1 (para vetores perpendiculares a x , pois esses vetores não se alteram) e -1 (para vetores proporcionais a x , pois estes invertem). É fácil ver algebricamente, tome v perpendicular a x .

$$Fv = Iv - 2xx^*v = v$$

Autovalor 1

$$Fx =Ix - 2xx^*x = x - 2x = -x$$

Autovalor -1

Os valores singulares são 1 pois, como já visto na primeira questão desta lista:

$$F^*F = FF^* = I$$

Q7.

Q8.

Suponha que a matriz $A \in C^{m \times n}$ tenha a forma

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix},$$

onde A_1 é uma matriz não singular de dimensão $n \times n$ e A_2 é uma matriz arbitrária de dimensão $(m-n) \times n$. Mostre que

$$\|A^+\|_2 \leq \|A_1^{-1}\|_2.$$

Como A_1 é inversível, as colunas de A são linearmente independentes. Logo, A possui posto completo n . Portanto,

$$A^+ = (A^*A)^{-1}A^*,$$

e assim

$$\|A^+\|_2 = \frac{1}{\sigma_{\min}(A)},$$

onde $\sigma_{\min}(A)$ denota o menor valor singular de A . De maneira análoga,

$$\|A_1^{-1}\|_2 = \frac{1}{\sigma_{\min}(A_1)}.$$

Portanto, basta mostrar que

$$\sigma_{\min}(A) \geq \sigma_{\min}(A_1).$$

Agora observe que

$$A^*A = A_1^*A_1 + A_2^*A_2.$$

Como $A_2^*A_2$ é positiva semidefinida,

$$A^*A \succeq A_1^*A_1.$$

Assim, para todo vetor não nulo x ,

$$x^*A^*Ax = x^*A_1^*A_1x + x^*A_2^*A_2x \geq x^*A_1^*A_1x.$$

Dividindo por $\|x\|^2$,

$$\frac{x^*A^*Ax}{\|x\|^2} \geq \frac{x^*A_1^*A_1x}{\|x\|^2}.$$

Tomando o mínimo sobre todos os vetores $x \neq 0$,

$$\lambda_{\min}(A^*A) \geq \lambda_{\min}(A_1^*A_1).$$

Como os autovalores de A^*A são os quadrados dos valores singulares,

$$\sigma_{\min}(A)^2 \geq \sigma_{\min}(A_1)^2.$$

Logo,

$$\sigma_{\min}(A) \geq \sigma_{\min}(A_1).$$

Invertendo ambos os lados,

$$\frac{1}{\sigma_{\min}(A)} \leq \frac{1}{\sigma_{\min}(A_1)}.$$

Portanto,

$$\boxed{\|A^+\|_2 \leq \|A_1^{-1}\|_2}.$$

Portanto, este problema é bem condicionado por qualquer critério.

Q9.

Suponha que A seja uma matriz 202×202 tal que

$$\|A\|_2 = 100 \quad \text{e} \quad \|A\|_F = 101.$$

Determine o melhor limitante inferior possível para o número de condição na norma 2,

$$\kappa(A) = \|A\|_2 \|A^{-1}\|_2.$$

Solução.

Sejam

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{202} \geq 0$$

os valores singulares de A .

Como

$$\|A\|_2 = \sigma_1 = 100,$$

e

$$\|A\|_F^2 = \sum_{i=1}^{202} \sigma_i^2 = 101^2 = 10201,$$

temos

$$\sum_{i=2}^{202} \sigma_i^2 = 10201 - 100^2 = 201.$$

O número de condição na norma 2 é dado por

$$\kappa(A) = \frac{\sigma_1}{\sigma_{202}} = \frac{100}{\sigma_{202}}.$$

Para obter o melhor limitante inferior possível para $\kappa(A)$, devemos maximizar σ_{202} sujeito à restrição

$$\sum_{i=2}^{202} \sigma_i^2 = 201.$$

O maior valor possível de σ_{202} ocorre quando

$$\sigma_2 = \sigma_3 = \cdots = \sigma_{202}.$$

Se esse valor comum é s , então

$$201s^2 = 201,$$

logo

$$s = 1.$$

Assim,

$$\sigma_{202} \leq 1,$$

e portanto

$$\kappa(A) = \frac{100}{\sigma_{202}} \geq 100.$$

Esse limite é atingido quando os valores singulares são

$$100, 1, 1, \dots, 1.$$

Portanto, o melhor limitante inferior possível é

$$\boxed{\kappa(A) \geq 100.}$$